

矩阵求导补充

写这篇是为了让读者能看懂原书的一条公式，关于那个公式原书略过了一些细节，对新手比较致命。

那个公式就是线性回归的解析解，其实读者完全可以跳过那个解析解，当然进而也可以跳过本节这么一大坨，但……来测吧！

这篇 theory 主要就是补充一下矩阵求导的细节，比如像一元微积分中对多项式求导的结论，可以加快计算的，再比如加法求导法则、链式求导法则之类的。

首先要先对矩阵求导有个基本印象，这里可以看我写的 [矩阵求导 \(isirin1131.github.io\)](https://isirin1131.github.io)。

其次，我们不需要对完整的矩阵求导建立代数系统，而只需要对向量求导建立理论和得出并记住一些基本结果，这对理解线性回归这一节中的公式已经足够了。（其实是我搞不定更高的理论）

约定：依据分子布局，所有的向量都是列向量

向量求导形如： 对于向量 \mathbf{x} ，其长度为 n ，形如 $\{x_1, x_2, \dots, x_n\}$ ，对于向量 \mathbf{y} ，也就是 $\mathbf{f}(\mathbf{x})$ ，其长度为 m ，形如 $\{f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})\}$ ，我们要求 $\frac{\partial}{\partial \mathbf{x}} \mathbf{y}$ ，得到的结果是个 $m \times n$ 的矩阵，并且如果 $\mathbf{y} \mathbf{x}^T$ 这个 $m \times n$ 矩阵的第 (i, j) 项是 $f_i(\mathbf{x}) x_j$ ，那么 $\frac{\partial}{\partial \mathbf{x}} \mathbf{y}$ 的第 (i, j) 项就是 $\frac{\partial}{\partial x_j} f_i(\mathbf{x})$ 。

几个基础的例子：

1. $\frac{\partial}{\partial \mathbf{x}} \mathbf{a}$ 等于 $\mathbf{0}$ (\mathbf{a} 是与 \mathbf{x} 无关的常数向量， $\mathbf{0}$ 是全零矩阵)，这个很容易推
2. $\frac{\partial}{\partial \mathbf{x}} \mathbf{x}$ 等于 $\mathbf{1}$ ($\mathbf{1}$ 是一个对角线为 1，其余地方为 0 的方阵)，这个也比较容易推
3. $\frac{\partial}{\partial \mathbf{x}} \mathbf{A} \mathbf{x}$ 等于 \mathbf{A} (\mathbf{A} 是个列数为 n 的矩阵，行数不做要求)，这个稍微有点难，就稍微讲讲，首先 $\mathbf{A} \mathbf{x}$ 是个列向量，而且 $\mathbf{A} \mathbf{x}$ 的每个分量都是 \mathbf{A} 的某个行向量与 \mathbf{x} 的点积，往后就显然了
4. $\frac{\partial}{\partial \mathbf{x}} \mathbf{x}^T \mathbf{A}$ 等于 \mathbf{A}^T ，这个跟上一个存在某种对应的关系，读者不需要管，硬推就行了。
5. $\frac{\partial}{\partial \mathbf{x}} \mathbf{x}^T \mathbf{A} \mathbf{x}$ ，这个稍微复杂，首先 $\mathbf{x}^T \mathbf{A} \mathbf{x}$ 是个标量，具体地，形如 $\mathbf{x}^T \mathbf{a}_1 x_1 + \mathbf{x}^T \mathbf{a}_2 x_2 + \dots + \mathbf{x}^T \mathbf{a}_n x_n$ (\mathbf{a}_i 是列向量)，然后 $\frac{\partial}{\partial \mathbf{x}} \mathbf{x}^T \mathbf{A} \mathbf{x}$ 就是行向量，但有点复杂，比如它第一项是 $\mathbf{x}^T \mathbf{a}_1 + a_{1,1} x_1 + a_{2,1} x_2 + \dots + a_{n,1} x_1$ ，第二项是 $\mathbf{x}^T \mathbf{a}_2 + a_{1,2} x_2 + a_{2,2} x_2 + \dots + a_{n,2} x_2$ ，到这个地步我们也能看出来了， $\frac{\partial}{\partial \mathbf{x}} \mathbf{x}^T \mathbf{A} \mathbf{x}$ 等于 $\mathbf{x}^T (\mathbf{A} + \mathbf{A}^T)$

6. $\frac{\partial}{\partial \mathbf{x}} |\mathbf{x}|^2$ 等于 $2\mathbf{x}^T$ ($|\mathbf{x}|^2$ 意思是向量长度的平方, 数值上等于 $\sum_{i=1}^n (x_i)^2$, 其实是个标量, 但我们也可以把它当成向量处理), 这个比较显然

这向量求导的这些性质怎么这么像标量求导的那些性质? 那既然如此, 四则运算求导法则和链式求导法则也存在吗?

存在。

首先, $\frac{\partial}{\partial \mathbf{x}} \alpha \mathbf{y} = \alpha \frac{\partial}{\partial \mathbf{x}} \mathbf{y}$, 其中 α 是标量, 这个很好验证; $\frac{\partial}{\partial \mathbf{x}} \mathbf{A} \mathbf{y} = \mathbf{A} \frac{\partial}{\partial \mathbf{x}} \mathbf{y}$ (其中 \mathbf{A} 是个列数为 m 的矩阵, 行数不做要求), 这个看着复杂, 实际上一推就有。

其次, $\frac{\partial}{\partial \mathbf{x}} (\mathbf{u} + \mathbf{v}) = \frac{\partial}{\partial \mathbf{x}} \mathbf{u} + \frac{\partial}{\partial \mathbf{x}} \mathbf{v}$, 其中 \mathbf{u}, \mathbf{v} 都长为 m , 形如 $\{f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})\}$ 。这个也是一推就有。

乘法法则没有, 不会推 (

(ps: 其实更弱的情况, 比如标量对向量求导, 是可以有乘法法则的, 但这里没有。)

最后, 链式法则也是成立的, 也就是 $\frac{\partial}{\partial \mathbf{x}} \mathbf{y} = \frac{\partial}{\partial \mathbf{u}} \mathbf{y} \frac{\partial}{\partial \mathbf{x}} \mathbf{u}$

证明这个挺简单, 矩阵乘一下就明白了, 但是要先知道一个理论 (不然证不了), 也就是原书里提到过的“多变量函数的链式法则”, 如下:

让我们先考虑单变量函数。假设函数 $y = f(u)$ 和 $u = g(x)$ 都是可微的, 根据链式法则:

$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}$. 现在考虑一个更一般的场景, 即函数具有任意数量的变量的情况。假设可微分函数 y 有变量 u_1, u_2, \dots, u_m , 其中每个可微分函数 u_i 都有变量 x_1, x_2, \dots, x_n 。注意, y 是 x_1, x_2, \dots, x_n 的函数。对于任意 $i = 1, 2, \dots, n$, 链式法则给出: $\frac{\partial y}{\partial x_i} = \frac{\partial y}{\partial u_1} \frac{\partial u_1}{\partial x_i} + \frac{\partial y}{\partial u_2} \frac{\partial u_2}{\partial x_i} + \dots + \frac{\partial y}{\partial u_m} \frac{\partial u_m}{\partial x_i}$

唉, 这个多变量函数的链式法则实际上是多变量微积分的内容, 我不会证, 读者自己了解吧。

我们主要关注的还是向量求导的链式法则。

完结, 不写了!